

UNIVERSIDADE ESTADUAL DE CAMPINAS
COLÉGIO TÉCNICO DE CAMPINAS - COTUCA

Arquitetura Documentada - See2Sound

24121, Clara Alves dos Santos

24136, João Victor Cussolim

Simone Pierini Facini Rocha

DEPARTAMENTO DE COMPUTAÇÃO

2026

ÍNDICE

1. Resumo.....	2
2. Plataforma Web.....	2
3. API de Gerenciamento.....	3
4. Módulo de Pré-processamento.....	3
5. IA de Reconhecimento Visual (Spectra).....	3
6. Voice Engine.....	3
7. Narrative Engine.....	4
8. Módulo de Sincronização.....	4
9. Speaker.....	4
10. Módulo de Composição.....	5
11. Conclusão.....	5

1. Resumo

A arquitetura do projeto See2Sound foi planejada de forma modular, com o objetivo de organizar o sistema em componentes independentes, porém integrados, facilitando o desenvolvimento, os testes e a manutenção da aplicação ao longo do projeto. Essa arquitetura permite que cada módulo seja responsável por uma etapa específica do processamento audiovisual, contribuindo para a geração automática de audiodescrição contextualizada a partir de mídias digitais.

O sistema tem como entrada principal um arquivo de vídeo enviado pelo usuário por meio da plataforma web. A partir desse envio, a aplicação inicia uma sequência de etapas de processamento que envolvem a extração de informações visuais e sonoras, a interpretação do conteúdo da mídia, a geração do texto da audiodescrição, a síntese de voz e, por fim, a inserção da narração no vídeo original. O resultado final do sistema é um novo arquivo audiovisual contendo a audiodescrição gerada automaticamente.

A arquitetura do See2Sound é composta pelos seguintes módulos principais: Plataforma Web, API de Gerenciamento, Módulo de Pré-processamento, IA de Reconhecimento Visual, Voice Engine, Narrative Engine, Speaker e Módulo de Composição Final do Vídeo.

2. Plataforma Web

Será responsável pela interação com o usuário. Por meio dela, o usuário poderá enviar mídias audiovisuais para processamento e receber, ao final, a versão do vídeo contendo audiodescrição gerada automaticamente. Essa interface será desenvolvida com foco em acessibilidade digital, buscando garantir usabilidade adequada para pessoas com deficiência visual.

3. API de Gerenciamento

Atuará como o núcleo de comunicação entre a interface web e os demais módulos internos do sistema. Sua responsabilidade será receber as requisições do usuário, organizar o fluxo de processamento, encaminhar arquivos para os módulos correspondentes e retornar o resultado final à plataforma. Dessa forma, a API funcionará como intermediadora entre entrada, processamento e saída do sistema.

4. Módulo de Pré-processamento

Será responsável por preparar a mídia para análise. Nessa etapa, o sistema realizará ações como validação do arquivo de vídeo, extração do áudio, separação de frames relevantes e organização inicial dos dados necessários para os módulos seguintes. Esse módulo é importante para padronizar a entrada do sistema e garantir que os demais componentes recebam dados em formato adequado para processamento.

Sua entrada é o arquivo de vídeo enviado pelo usuário, e suas saídas incluem o áudio extraído, frames relevantes e metadados do vídeo.

5. IA de Reconhecimento Visual (Spectra)

Spectra será responsável por analisar os frames extraídos do vídeo e identificar elementos visuais relevantes para a compreensão da narrativa. Entre esses elementos podem estar personagens, ações, objetos, mudanças de cenário e eventos importantes para o entendimento da cena. Esse módulo representa a principal camada de percepção visual do sistema e fornecerá as informações necessárias para a construção da audiodescrição.

Recebe como entrada os frames selecionados do vídeo e tem como saída a identificação de eventos visuais relevantes, como personagens, ações, objetos e mudanças de cenário.

6. Voice Engine

O Voice Engine será responsável por identificar os momentos em que há fala e os intervalos disponíveis para inserção da audiodescrição. Essa etapa é fundamental para evitar sobreposição com os diálogos originais da mídia e garantir que a narração gerada seja inserida de forma adequada no fluxo do vídeo. Esse módulo poderá também auxiliar na obtenção de informações temporais que serão utilizadas para sincronizar a descrição com o conteúdo audiovisual.

Recebe como entrada o áudio extraído do vídeo e produz como saída a identificação de falas, pausas e intervalos disponíveis para inserção da audiodescrição.

7. Narrative Engine

O Módulo de Geração Narrativa receberá as informações vindas da IA visual e do módulo de análise de áudio, transformando esses dados em descrições textuais coerentes com o conteúdo apresentado. Esse componente será responsável por estruturar a audiodescrição em linguagem natural, priorizando elementos relevantes da cena e respeitando o contexto narrativo da mídia analisada.

Recebe como entrada o áudio extraído do vídeo e produz como saída a identificação de falas, pausas e intervalos disponíveis para inserção da audiodescrição.

8. Módulo de Sincronização

É responsável por integrar as informações visuais e sonoras do sistema. Esse módulo define quais descrições serão utilizadas, em quais momentos serão inseridas e como serão adaptadas ao tempo disponível, sendo fundamental para garantir a contextualização da audiodescrição.

Ele recebe como entrada as descrições geradas e os intervalos de tempo disponíveis, e como saída produz descrições finais ajustadas ao tempo do vídeo.

9. Speaker

O Módulo de Síntese de Voz terá como função converter o texto gerado pela audiodescrição em áudio narrado. Esse processo permitirá que a descrição deixe de existir apenas como texto e passe a ser incorporada efetivamente à experiência

audiovisual. O áudio gerado por esse módulo será posteriormente utilizado na etapa de composição final do vídeo.

Recebe como entrada o texto da audiodescrição final e gera como saída o áudio narrado correspondente.

10. Módulo de Composição

O Módulo de Composição Final do Vídeo será responsável por unir o vídeo original, o áudio original da mídia e a narração gerada automaticamente. Nessa etapa, o sistema inserirá a audiodescrição nos momentos apropriados da linha do tempo do vídeo, respeitando pausas previamente identificadas e mantendo a coerência entre imagem, fala e narração. Ao final desse processo, será exportada a mídia final audiodescrita.

Recebe como entrada o vídeo original e os áudios gerados pela síntese de voz, como saída produz o vídeo final com audiodescrição integrada.

11. Conclusão

Durante o processamento, o sistema poderá utilizar armazenamento temporário para manter arquivos intermediários, como áudio extraído, frames selecionados, descrições geradas e áudios sintetizados. Essa estratégia permite organizar o fluxo de dados e facilitar a execução das etapas da pipeline.

De forma geral, o fluxo do sistema ocorre da seguinte maneira: o usuário envia um vídeo pela plataforma web; a API recebe e encaminha o arquivo para o módulo de pré-processamento; o conteúdo é analisado pelos módulos visual e de áudio; as informações obtidas são utilizadas para gerar descrições textuais; essas descrições são sincronizadas com os intervalos disponíveis; o texto é convertido em áudio; e, por fim, o sistema integra a narração ao vídeo original e retorna o resultado ao usuário.

Essa arquitetura modular permite que cada componente seja desenvolvido, testado e aprimorado de forma independente, contribuindo para a organização do projeto e para a qualidade técnica do sistema. Além disso, a separação clara entre os módulos facilita futuras melhorias e adaptações, tornando o See2Sound uma solução robusta e viável para a geração automática de audiodescrição.