UNIVERSIDADE ESTADUAL DE CAMPINAS
COLÉGIO TÉCNICO DE CAMPINAS - COTUCA

CLARA ALVES DOS SANTOS
JOÃO VICTOR CUSSOLIM

SEE2SOUND

Sistema de geração automática de audiodescrição contextualizada para conteúdos audiovisuais utilizando inteligência artificial

PLANO DE PESQUISA

Campinas
2026

CLARA ALVES DOS SANTOS
JOÃO VICTOR CUSSOLIM

SEE2SOUND

Sistema de geração automática de audiodescrição contextualizada para conteúdos audiovisuais utilizando inteligência artificial

Plano de pesquisa apresentado ao Colégio Técnico de Campinas - COTUCA, da Universidade Estadual de Campinas.
Orientadora: Simone Pierini Facini Rocha.

Instituição: Universidade Estadual de Campinas - Colégio Técnico de Campinas (COTUCA).
Departamento: Departamento de Computação.
Período de desenvolvimento: março a setembro de 2026.

Campinas
2026

SUMÁRIO

1 INTRODUÇÃO E PROBLEMA DE PESQUISA 3
2 JUSTIFICATIVA 5
3 OBJETIVOS 7
3.1 Objetivo geral de engenharia 7
3.2 Objetivos específicos 7
4 MATERIAIS E MÉTODOS 9
4.1 Natureza e abordagem do projeto 9
4.2 Arquitetura e procedimento de desenvolvimento 9
4.2.1 Submodelos da Spectra 10
4.3 Materiais e recursos tecnológicos 13
4.4 Procedimentos de teste e avaliação 13
4.5 Questões éticas, segurança e boas práticas 15
5 CRONOGRAMA 16
REFERÊNCIAS 17

1 INTRODUÇÃO E PROBLEMA DE PESQUISA

Os conteúdos audiovisuais ocupam papel central na comunicação, no entretenimento, na educação e na circulação de informações em plataformas digitais. Entretanto, grande parte desses conteúdos depende de informações visuais que não são transmitidas integralmente pelo áudio original, o que pode criar barreiras de acesso para pessoas cegas ou com baixa visão. A Organização Mundial da Saúde estima que pelo menos 2,2 bilhões de pessoas no mundo apresentam algum tipo de deficiência visual para perto ou para longe, evidenciando a dimensão social de soluções de acessibilidade voltadas à informação e à cultura (Organização Mundial da Saúde, 2026).

A audiodescrição é um recurso de acessibilidade que traduz em linguagem verbal informações visuais relevantes, como ações, ambientação, expressões, figurinos, personagens e mudanças de cena. No audiovisual, sua qualidade depende não apenas da identificação correta do que aparece na imagem, mas também da seleção do que é narrativamente relevante e da inserção da descrição em momentos que não prejudiquem diálogos e sons essenciais. Diretrizes brasileiras de acessibilidade cultural reforçam a importância da audiodescrição para ampliar a fruição de obras por pessoas com deficiência visual (Brasil, 2026).

Apesar de sua importância, a produção tradicional de audiodescrição exige análise humana especializada, roteirização, revisão, locução e sincronização, etapas que demandam tempo e recursos. Os avanços recentes em visão computacional, processamento de áudio, modelos de linguagem e síntese de voz permitem investigar soluções capazes de automatizar parte desse fluxo. O projeto See2Sound propõe uma arquitetura modular que recebe um vídeo, extrai e analisa seus componentes visuais e sonoros, gera descrições textuais, seleciona intervalos adequados para a narração, sintetiza a voz e compõe uma nova mídia com audiodescrição integrada.

Problema de pesquisa: como desenvolver um sistema computacional capaz de gerar automaticamente audiodescrições contextualizadas para vídeos digitais, identificando informações visuais relevantes e inserindo a narração em intervalos adequados, sem sobrepor falas importantes e preservando a coerência narrativa do conteúdo?

As principais limitações previstas estão relacionadas à diversidade de estilos audiovisuais, à possibilidade de erros de reconhecimento por modelos de inteligência artificial, à necessidade de reduzir descrições redundantes ou não verificáveis, ao custo computacional do processamento de vídeo e à dificuldade de sincronizar descrições suficientemente informativas com pausas de duração limitada.

2 JUSTIFICATIVA

O See2Sound é motivado pela necessidade de ampliar o acesso de pessoas com deficiência visual a conteúdos audiovisuais digitais que não possuem faixa de audiodescrição. A ausência desse recurso pode limitar a compreensão de ações, cenários, personagens e acontecimentos transmitidos apenas visualmente, reduzindo a autonomia do usuário e seu acesso a experiências culturais, educacionais e informativas.

A relevância social do projeto está associada ao princípio de que recursos digitais devem ser projetados para diferentes formas de interação. No caso da plataforma web prevista para o See2Sound, serão adotados critérios de acessibilidade compatíveis com as recomendações WCAG 2.2, que orientam a construção de conteúdo web mais acessível, inclusive para pessoas cegas e com baixa visão (W3C, 2024).

Do ponto de vista técnico e científico, o projeto integra áreas que normalmente são tratadas separadamente: visão computacional, análise temporal de áudio, geração de linguagem natural, síntese de voz, processamento audiovisual e acessibilidade web. A arquitetura modular permite avaliar cada etapa de forma independente e, posteriormente, medir o comportamento do sistema completo, favorecendo a identificação de falhas e a evolução de componentes específicos.

O diferencial pretendido não é apenas converter imagens em frases isoladas, mas produzir uma audiodescrição contextualizada. Para isso, o sistema deverá priorizar eventos relevantes, reduzir repetições, respeitar a continuidade entre cenas e escolher intervalos nos quais a descrição possa ser ouvida sem competir com diálogos originais, além de integrar um modelo que grave elementos como nomes de personagens e objetos importantes e os reproduza na audiodescrição gerada. Esse princípio se aproxima da concepção de audiodescrição como tradução audiovisual que deve considerar a experiência narrativa da obra, e não apenas enumerar elementos presentes na imagem (David; Hautequestt; Kastrup, 2012).

Como resultados esperados, pretende-se obter um protótipo funcional capaz de processar vídeos de diferentes características, gerar descrições textuais coerentes com os eventos visuais detectados, sintetizar essas descrições em áudio e produzir uma versão final do vídeo com a narração integrada. Espera-se também

obter dados de desempenho e qualidade que permitam identificar os limites atuais da solução e orientar melhorias futuras.

3 OBJETIVOS

Por se tratar de um projeto de engenharia, adota-se um objetivo de engenharia em lugar de uma hipótese científica: construir e avaliar uma solução tecnológica para uma necessidade de acessibilidade previamente identificada.

3.1 Objetivo geral de engenharia

Desenvolver e validar um sistema modular baseado em inteligência artificial capaz de analisar conteúdos audiovisuais digitais e gerar automaticamente audiodescrição contextualizada, sincronizada com os intervalos de fala e disponibilizada ao usuário por meio de uma plataforma web acessível.

3.2 Objetivos específicos

- Desenvolver um módulo de pré-processamento capaz de validar o vídeo, extrair o áudio, selecionar frames e identificar mudanças relevantes de cena.
- Implementar o módulo Spectra e seus submodelos especializados para reconhecer e correlacionar informações visuais relevantes, incluindo personagens, características visuais, ações, objetos, condições atmosféricas e cenários, estabelecendo relações temporais entre os eventos identificados.
- Implementar um Voice Engine capaz de detectar falas, pausas e intervalos úteis para inserção da audiodescrição.
- Desenvolver um Narrative Engine capaz de transformar eventos visuais estruturados em descrições naturais, coerentes, não redundantes e compatíveis com o contexto do vídeo.
- Desenvolver um módulo de sincronização que selecione e ajuste as descrições de acordo com o tempo disponível na linha do tempo.
- Converter as descrições finais em áudio por meio de síntese de voz e integrar a narração ao vídeo original.
- Desenvolver uma plataforma web acessível para envio de vídeos, acompanhamento do processamento e recebimento do conteúdo final.
- Realizar testes de unidade, integração e funcionalidade com vídeos de diferentes gêneros e características.

- Avaliar a fidelidade das descrições, a adequação temporal da narração, a ocorrência de sobreposição com falas e o tempo de processamento do sistema.

4 MATERIAIS E MÉTODOS

4.1 Natureza e abordagem do projeto

O trabalho será conduzido pelo método de engenharia, com caráter aplicado e desenvolvimento incremental de um protótipo de software. A avaliação terá natureza experimental, pois diferentes entradas audiovisuais serão utilizadas para observar como as alterações de conteúdo, duração, número de cenas, quantidade de falas e complexidade visual afetam a qualidade e o desempenho do sistema.

O desenvolvimento será organizado em ciclos curtos, com implementação, testes e revisão de cada módulo antes da integração. Essa estratégia busca reduzir o impacto de falhas entre componentes e facilitar a substituição ou o aprimoramento de modelos e bibliotecas ao longo do projeto.

4.2 Arquitetura e procedimento de desenvolvimento

A arquitetura do See2Sound será composta por módulos independentes e integrados. O fluxo geral seguirá as seguintes etapas: recepção do vídeo, pré-processamento, análise visual, análise de áudio, geração narrativa, sincronização, síntese de voz, composição e entrega do conteúdo final.

Na etapa de pré-processamento, o arquivo audiovisual será validado e preparado para análise. O sistema realizará a extração da faixa de áudio, a seleção de quadros relevantes e a organização dos metadados temporais necessários para os módulos seguintes.

A análise visual será realizada pelo módulo Spectra, responsável por interpretar os quadros extraídos do vídeo e transformar as informações visuais em dados estruturados. Diferentemente de uma abordagem baseada em um único modelo de reconhecimento, a Spectra será organizada em seis submodelos especializados: Person, Actions, Object, Atmosphere, Scene e Correlational.

4.2.1 Submodelos da Spectra

O Person será responsável pela identificação e caracterização de pessoas presentes nas cenas. O modelo deverá detectar a presença de indivíduos e reconhecer características visuais relevantes para a continuidade narrativa, como vestimentas e outros elementos associados à aparência dos personagens. Essas

informações poderão ser utilizadas posteriormente para auxiliar na diferenciação e no acompanhamento de personagens ao longo do vídeo.

O Actions será responsável pela identificação das ações realizadas pelas pessoas detectadas. Entre os elementos analisados poderão estar poses corporais, deslocamentos e atividades como caminhar, correr, sentar-se ou interagir com outros elementos da cena. Sua saída complementará as informações do Person, permitindo identificar não apenas quem está presente, mas também quais ações estão sendo realizadas.

O Object será destinado à identificação dos objetos presentes no ambiente audiovisual. Seu objetivo será reconhecer elementos gerais da cena que possam possuir relevância narrativa, como veículos, móveis, equipamentos, utensílios ou outros objetos utilizados pelos personagens ou importantes para a compreensão dos acontecimentos.

O Atmosphere será responsável pela análise das condições visuais associadas à atmosfera da cena, incluindo aspectos como iluminação, luminosidade e condições climáticas. Esse modelo permitirá complementar as informações objetivas dos elementos presentes com características relacionadas às condições em que os acontecimentos ocorrem, como cenas noturnas, ambientes pouco iluminados ou situações de chuva.

O Scene realizará a classificação da ambientação geral apresentada no vídeo. Sua função será identificar o tipo de espaço no qual a cena ocorre, como escritório, banheiro, rua, quarto, cozinha ou outros ambientes reconhecíveis. Essa informação fornecerá ao sistema uma representação do contexto espacial em que os eventos identificados acontecem.

Por fim, o Correlational funcionará como o módulo central de correlação e orquestração das informações produzidas pelos demais submodelos da Spectra. Em vez de analisar cada quadro de maneira completamente independente, esse componente deverá relacionar as detecções realizadas ao longo do tempo, permitindo estabelecer continuidade entre diferentes momentos do vídeo.

O Correlational terá como objetivo associar informações referentes a personagens, ações, objetos, ambientes e características atmosféricas, mantendo registros temporais que auxiliem na identificação de elementos recorrentes. Dessa forma, o sistema poderá reconhecer, por exemplo, que uma pessoa identificada em diferentes cenas corresponde ao mesmo personagem, ainda que sua posição, pose, iluminação ou enquadramento tenham sido alterados.

A correlação temporal constitui uma etapa central da proposta do See2Sound, pois permitirá que a Spectra deixe de realizar exclusivamente a interpretação isolada dos quadros e passe a construir uma representação progressiva do conteúdo audiovisual. Assim, em vez de produzir somente conjuntos independentes de elementos visuais a cada quadro, o sistema buscará estabelecer relações entre acontecimentos anteriores e posteriores, contribuindo para a manutenção da continuidade e da coerência narrativa.

As saídas produzidas pelos cinco submodelos de análise serão consolidadas pelo Correlational em uma representação estruturada dos eventos visuais identificados. Essa representação poderá conter informações referentes aos personagens presentes, suas características visuais, ações realizadas, objetos relevantes, ambiente da cena, condições atmosféricas e relações temporais com eventos anteriormente identificados.

Após essa etapa, os dados consolidados pela Spectra serão encaminhados ao Narrative Engine, responsável por transformá-los em descrições textuais em linguagem natural. O módulo narrativo utilizará as informações correlacionadas para priorizar acontecimentos relevantes, reduzir redundâncias e produzir descrições coerentes com o contexto acumulado do vídeo.

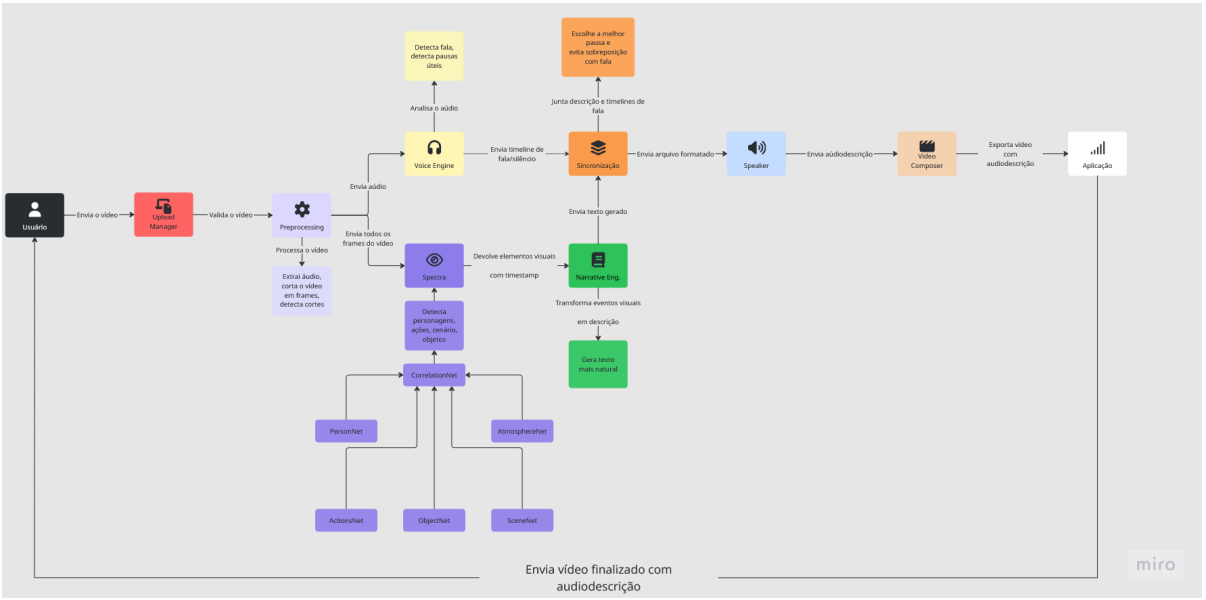
Paralelamente, o Voice Engine analisará a faixa de áudio original para identificar momentos de fala, silêncio e pausas disponíveis para inserção da audiodescrição. Esses dados temporais serão posteriormente combinados às descrições geradas.

O módulo de Sincronização receberá as descrições textuais e os intervalos identificados pelo Voice Engine, determinando quais descrições poderão ser

inseridas em cada momento da mídia e realizando ajustes quando o tempo disponível for limitado.

Em seguida, o módulo Speaker converterá as descrições selecionadas em áudio por meio de síntese de voz. Por fim, o módulo de Composição combinará o vídeo original, sua faixa de áudio e a narração sintetizada, produzindo um novo arquivo audiovisual com audiodescrição integrada.

Figura 1 - Pipeline geral do sistema See2Sound



Fonte: elaboração própria (2026).

4.3 Materiais e recursos tecnológicos

- Computadores pessoais e equipamentos disponíveis no Colégio Técnico de Campinas (COTUCA) para desenvolvimento e testes.
- Python como linguagem principal dos módulos de processamento audiovisual e inteligência artificial.
- Bibliotecas de visão computacional e processamento de vídeo, incluindo OpenCV ou ferramentas equivalentes.
- Frameworks e bibliotecas para execução e treinamento de modelos de inteligência artificial, incluindo PyTorch quando aplicável.
- Ferramentas de processamento de áudio e reconhecimento de fala para detecção de trechos falados, silêncio e timestamps.
- Modelo de linguagem executado localmente ou solução equivalente para geração das descrições em linguagem natural.

- Ferramenta de síntese de voz para conversão das descrições textuais em áudio.
- Ferramentas de composição e manipulação de mídia, como FFmpeg ou equivalentes.
- Tecnologias web para desenvolvimento da interface acessível e da API de gerenciamento.
- Repositórios Git para versionamento, revisão de código e acompanhamento da evolução do sistema.

4.4 Procedimentos de teste e avaliação

Os testes serão realizados em três níveis: unidade, integração e funcionalidade. Nos testes de unidade, cada componente será avaliado isoladamente com entradas controladas. Nos testes de integração, será verificada a transmissão correta de dados entre os módulos. Nos testes de funcionalidade, o fluxo completo será executado desde o envio do vídeo até a geração da mídia final.

Serão utilizados vídeos com diferentes durações, quantidades de diálogo, cenários, número de personagens e intensidade de movimento. A seleção buscará incluir cenas simples e complexas, permitindo observar a capacidade de generalização do sistema. Sempre que possível, serão utilizados vídeos de domínio público, materiais próprios ou arquivos com autorização de uso.

As principais variáveis e critérios de avaliação serão:

- Fidelidade visual: proporção de descrições que correspondem aos elementos efetivamente presentes na cena e ausência de informações inventadas ou não verificáveis.
- Relevância narrativa: capacidade de priorizar ações, personagens e mudanças de contexto importantes para a compreensão do vídeo.
- Redundância: frequência de descrições repetitivas ou excessivamente semelhantes em uma mesma sequência.
- Adequação temporal: compatibilidade entre a duração da narração e o intervalo disponível para inserção.
- Sobreposição de fala: ocorrência de narração sobre diálogos ou sons essenciais do conteúdo original.
- Tempo de processamento: relação entre a duração do vídeo e o tempo necessário para concluir o processamento; como meta inicial de engenharia,

será observado o desempenho em relação à estimativa de aproximadamente 20 segundos de processamento para cada minuto de vídeo.

- Robustez do fluxo: capacidade de concluir o processamento sem falhas críticas em diferentes arquivos e condições de entrada.
- Acessibilidade da plataforma: navegação por teclado, semântica adequada dos componentes, mensagens compreensíveis e compatibilidade com tecnologias assistivas, tomando a WCAG 2.2 como referência.

Os resultados serão registrados em planilhas ou arquivos estruturados contendo, para cada vídeo, duração, número de cenas analisadas, quantidade de descrições produzidas, falhas observadas, sobreposições, tempo total de processamento e avaliação qualitativa da coerência das descrições. A comparação entre execuções permitirá identificar gargalos e orientar ajustes nos módulos.

4.5 Questões éticas, segurança e boas práticas

O projeto não prevê experimentação física, biológica ou química. Os principais cuidados envolvem uso responsável de mídias digitais, privacidade e avaliação de acessibilidade. Durante o desenvolvimento serão priorizados vídeos próprios, de domínio público ou cujo uso seja autorizado, evitando a redistribuição indevida de conteúdo protegido.

Caso sejam realizados testes de usabilidade com participantes humanos, especialmente pessoas com deficiência visual, essa etapa será conduzida somente após verificação das exigências éticas aplicáveis à feira e à instituição, com consentimento dos participantes e registro apenas dos dados necessários à avaliação. A automação proposta não será apresentada como substituta integral do trabalho profissional de audiodescrição; os resultados serão tratados como protótipo de apoio tecnológico sujeito a erros e limitações.

5 CRONOGRAMA

O cronograma consolida as sprints definidas no planejamento técnico e acrescenta as etapas de integração, testes, acessibilidade e documentação necessárias para a conclusão do protótipo e sua submissão à feira.

Tabela 1 - Cronograma de execução do projeto See2Sound

Período	Atividade
Março/2026	Pesquisa bibliográfica, definição da arquitetura e preparação do ambiente.
Março–abril/2026	Pré-processamento de vídeo, extração de áudio, separação de frames e detecção de mudanças de cena.
Abril–maio/2026	Detecção de fala, silêncio e intervalos possíveis para audiodescrição.
Maio/2026	Implementação e testes do módulo Spectra de reconhecimento visual.
Maio–junho/2026	Desenvolvimento do Narrative Engine e geração de audiodescrição textual.
Junho–julho/2026	Integração dos módulos, sincronização, síntese de voz e composição final do vídeo.
Junho–agosto/2026	Desenvolvimento e refinamento da plataforma web acessível.
Julho–setembro/2026	Testes de unidade, integração, funcionalidade, desempenho e acessibilidade.
Agosto–setembro/2026	Análise dos resultados, otimização dos módulos e documentação final.
Setembro/2026	Revisão do relatório, organização dos anexos e submissão do projeto à feira.

Fonte: elaboração própria (2026).

REFERÊNCIAS

BRASIL. Ministério dos Direitos Humanos e da Cidadania. **Guia de Boas Práticas de Acessibilidade em Cinema: orientações para produtoras, distribuidoras, exibidores e plataformas de ingressos.** Brasília, DF: MDHC, 2026. Disponível em: https://www.gov.br/mdh/pt-br/navegue-por-temas/pessoa-com-deficiencia/publicacoes/guia-de-boas-praticas-de-acessibilidade-em-cinema. Acesso em: 27 ago. 2026.

DAVID, Jéssica; HAUTEQUESTT, Felipe; KASTRUP, Virginia. **Audiodescrição de filmes: experiência, objetividade e acessibilidade cultural.** Fractal: Revista de Psicologia, Niterói, v. 24, n. 1, p. 125-142, 2012. DOI: 10.1590/S1984-02922012000100009.

ORGANIZAÇÃO MUNDIAL DA SAÚDE. **Blindness and vision impairment.** Geneva: WHO, 2026. Disponível em: https://www.who.int/news-room/fact-sheets/detail/blindness-and-visual-impairment. Acesso em: 27 ago. 2026.

WORLD WIDE WEB CONSORTIUM. **Web Content Accessibility Guidelines (WCAG) 2.2.** W3C Recommendation, 12 dez. 2024. Disponível em: https://www.w3.org/TR/WCAG22/. Acesso em: 27 ago. 2026.