UNIVERSIDADE ESTADUAL DE CAMPINAS
COLÉGIO TÉCNICO DE CAMPINAS - COTUCA

CLARA ALVES DOS SANTOS
JOÃO VICTOR CUSSOLIM

SEE2SOUND

Sistema de geração automática de audiodescrição contextualizada para conteúdos audiovisuais utilizando inteligência artificial

RELATÓRIO DO PROJETO

Campinas
2026

CLARA ALVES DOS SANTOS
JOÃO VICTOR CUSSOLIM

SEE2SOUND

Sistema de geração automática de audiodescrição contextualizada para conteúdos audiovisuais utilizando inteligência artificial

Relatório de projeto apresentado para inscrição em feira científica, desenvolvido no Colégio Técnico de Campinas (COTUCA), Universidade Estadual de Campinas (UNICAMP).
Orientadora: Simone Pierini Facini Rocha.

Instituição: Universidade Estadual de Campinas - Colégio Técnico de Campinas (COTUCA).
Departamento: Departamento de Computação.
Período de desenvolvimento: março a setembro de 2026.

Campinas
2026

AGRADECIMENTOS

Agradecemos à professora Simone Pierini Facini Rocha, orientadora do projeto, pelo acompanhamento, pelas orientações, pelo apoio durante o desenvolvimento do See2Sound e por todos os conselhos que levaremos para nossa vida.

Agradecemos aos amigos, que sempre estiveram ao nosso lado, pela amizade incondicional e pelo apoio demonstrado ao longo de todo o período de tempo em que nos dedicamos a este trabalho.

Agradecemos ao professor Guilherme de Oliveira Macedo, por todos os conselhos, pela ajuda e todos os ensinamentos que nos ajudaram a construir o See2Sound.

Agradecemos também ao Colégio Técnico de Campinas (COTUCA) e à Universidade Estadual de Campinas (UNICAMP), especialmente ao Departamento de Computação, pela formação, pela infraestrutura e pelo ambiente que possibilitaram o desenvolvimento deste trabalho.

Agradecemos aos professores, colegas e demais pessoas que contribuíram, direta ou indiretamente, com discussões, testes, sugestões e incentivo ao longo das diferentes etapas do projeto. Por fim, registramos nosso agradecimento a todos que trabalham pela ampliação da acessibilidade digital e audiovisual, cuja atuação reforça a importância de desenvolver tecnologias que contribuam para um acesso mais inclusivo à informação, à cultura e ao entretenimento.

RESUMO

O See2Sound é um projeto de engenharia de software voltado à acessibilidade audiovisual. Seu objetivo é desenvolver um sistema capaz de receber vídeos digitais, identificar informações visuais relevantes, localizar intervalos adequados no áudio original e produzir audiodescrição contextualizada de forma automática. A solução é organizada em uma arquitetura modular composta por pré-processamento de vídeo, análise de áudio, reconhecimento visual por inteligência artificial (Spectra), geração textual por modelo de linguagem (Narrative Engine), sincronização, síntese de voz e composição final. O desenvolvimento foi conduzido incrementalmente, com testes isolados e integrados dos módulos. O backend desenvolvido contém rotinas para extração de áudio e frames, detecção de cenas, análise de pausas por reconhecimento de fala, modelos especializados da Spectra para cenas, pessoas, ações e objetos, geração narrativa local com Llama 3.2 1B e componentes de síntese de voz e mixagem. Os testes realizados demonstraram o funcionamento do pipeline Spectra→Narrative e sua capacidade de produzir descrições naturais a partir das informações visuais identificadas; entretanto, também evidenciaram divergências semânticas, como troca de gênero e alteração de ações detectadas, reforçando a necessidade de filtros de fidelidade, refinamento dos modelos e avaliação sistemática. Os resultados obtidos demonstram a viabilidade técnica da arquitetura proposta e fornecem uma base consistente para o aprimoramento da integração, da avaliação quantitativa e dos mecanismos de acessibilidade. O projeto busca contribuir para ampliar o acesso de pessoas cegas ou com baixa visão a conteúdos audiovisuais que não dispõem de audiodescrição produzida profissionalmente.

Palavras-chave: audiodescrição; acessibilidade; inteligência artificial; visão computacional; processamento audiovisual.

SUMÁRIO

1 INTRODUÇÃO 6
1.1 Contextualização e problema 6
1.2 Justificativa e relevância 6
1.3 Objetivos 7
2 FUNDAMENTAÇÃO TEÓRICA 8
2.1 Audiodescrição e acessibilidade cultural 8
2.2 Inteligência artificial aplicada ao audiovisual 8
2.3 Acessibilidade digital 9
3 MATERIAIS E MÉTODOS 10
3.1 Natureza do projeto 10
3.2 Arquitetura do sistema 10
3.3 Pré-processamento audiovisual 11
3.4 Spectra: reconhecimento visual 11
3.5 Narrative Engine 12
3.6 Voice Engine, sincronização e composição 12
3.7 Testes e critérios de avaliação 13
4 DESENVOLVIMENTO DO PROJETO 14
4.1 Organização em etapas 14
4.2 Evolução registrada no repositório 14
5 RESULTADOS E ANÁLISE DOS DADOS 15
5.1 Estado atual dos módulos 15
5.2 Teste integrado Spectra → Narrative 15
5.3 Limitações identificadas 16
6 DISCUSSÃO 18
7 CONCLUSÕES 20
8 TRABALHOS FUTUROS 21

1 INTRODUÇÃO

1.1 Contextualização e problema

O crescimento do consumo de vídeos em plataformas digitais ampliou a importância da acessibilidade audiovisual. Filmes, séries, vídeos educacionais, transmissões ao vivo e conteúdos de redes sociais frequentemente comunicam informações essenciais somente por meio da imagem. Para pessoas cegas ou com baixa visão, essa dependência do canal visual pode impedir a compreensão integral da narrativa, mesmo quando o áudio original está disponível.

A Organização Mundial da Saúde estima que pelo menos 2,2 bilhões de pessoas apresentam deficiência visual para perto ou para longe. Esse dado evidencia a dimensão global de soluções que ampliem o acesso à informação e à cultura por meios não exclusivamente visuais (ORGANIZAÇÃO MUNDIAL DA SAÚDE, 2026).

A audiodescrição é um recurso de acessibilidade que traduz em linguagem verbal informações visuais relevantes. Em uma obra audiovisual, isso inclui ações, personagens, objetos, cenários, expressões e mudanças de contexto que contribuam para a compreensão do conteúdo. Entretanto, a produção profissional de audiodescrição envolve etapas de análise, roteirização, revisão, locução e sincronização, o que dificulta sua presença em grande parte do conteúdo publicado diariamente na internet.

O problema de engenharia abordado pelo See2Sound consiste em desenvolver uma solução computacional capaz de automatizar parte desse processo sem reduzir a audiodescrição a uma simples enumeração de objetos. A proposta busca analisar simultaneamente o conteúdo visual e a estrutura temporal do áudio, gerar descrições em linguagem natural e posicioná-las em intervalos adequados, evitando a sobreposição com falas relevantes.

1.2 Justificativa e relevância

A motivação inicial do projeto surgiu da observação de conteúdos digitais em que grande parte do entendimento depende daquilo que aparece na tela. Em situações desse tipo, o áudio original sozinho não comunica eventos visuais, movimentações ou alterações de cena. A automação da audiodescrição pode, portanto, funcionar como ferramenta complementar para ampliar a disponibilidade

desse recurso em materiais que não receberiam uma faixa acessível de forma manual.

A relevância do See2Sound também está na integração de diferentes áreas técnicas em um único fluxo: processamento de vídeo, reconhecimento de fala, detecção de pausas, visão computacional, classificação multirrótulo, modelos de linguagem, síntese de voz, sincronização audiovisual e acessibilidade web. Essa integração permite investigar não apenas a capacidade de cada modelo isolado, mas a qualidade final produzida quando todas as etapas precisam compartilhar contexto e tempo.

1.3 Objetivos

O objetivo geral é desenvolver e avaliar um sistema modular baseado em inteligência artificial capaz de gerar automaticamente audiodescrição contextualizada para conteúdos audiovisuais digitais.

Como objetivos específicos, definiram-se:

- processar vídeos e extrair metadados, áudio, frames e mudanças de cena;
- identificar trechos falados e pausas úteis à inserção de audiodescrição;
- detectar cenas, pessoas, ações e objetos visualmente relevantes por meio do módulo Spectra;
- converter eventos visuais estruturados em descrições naturais por meio do Narrative Engine;
- reduzir redundâncias e informações não sustentadas pelas detecções;
- sintetizar as descrições em voz e integrá-las ao fluxo audiovisual;
- disponibilizar a solução por meio de uma interface acessível;
- realizar testes de unidade, integração, funcionalidade, fidelidade narrativa e desempenho.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Audiodescrição e acessibilidade cultural

A audiodescrição pode ser compreendida como uma modalidade de tradução intersemiótica em que informações percebidas visualmente são convertidas em linguagem verbal. Sua função não é narrar indiscriminadamente tudo o que aparece em uma cena, mas selecionar elementos relevantes à experiência do espectador. David, Hautequestt e Kastrup (2012) destacam que a audiodescrição precisa considerar a experiência narrativa e as peculiaridades do público com deficiência visual, o que torna insuficiente uma abordagem puramente descritiva baseada em rótulos isolados.

Essa característica é central para o See2Sound. Um sistema automático pode reconhecer que há uma pessoa, uma rua e movimento, mas ainda precisa decidir quais informações são relevantes, como articulá-las em uma frase coerente, como evitar inferências não verificadas e em qual momento inserir a descrição. A dificuldade principal, portanto, não está apenas na visão computacional, mas na combinação entre percepção, seleção e linguagem.

2.2 Inteligência artificial aplicada ao audiovisual

O processamento automático de vídeos combina problemas de visão computacional e análise temporal. Em vez de tratar o vídeo como uma imagem única, o sistema precisa selecionar frames, reconhecer mudanças de cena e preservar relações entre eventos que acontecem ao longo do tempo. No See2Sound, a arquitetura separa essas responsabilidades em submodelos e módulos especializados, o que permite ajustar cada etapa sem reconstruir toda a solução.

O reconhecimento visual foi estruturado em torno da Spectra, composta por modelos para diferentes categorias de informação. A arquitetura atual do repositório contém módulos separados para ações, correlação, objetos e outros componentes, além de um preditor responsável por unificar as saídas. Para geração textual, utiliza-se um modelo de linguagem local, reduzindo a dependência de serviços externos e permitindo controlar parâmetros e filtros de fidelidade.

2.3 Acessibilidade digital

A acessibilidade do sistema não depende apenas da qualidade da audiodescrição gerada. A própria interface utilizada para enviar o vídeo e receber o resultado precisa ser navegável por pessoas com deficiência. As Web Content Accessibility Guidelines (WCAG) 2.2 reúnem recomendações para tornar conteúdo web mais acessível a pessoas com diferentes deficiências, incluindo cegueira e baixa visão (W3C, 2024). Por isso, a plataforma associada ao See2Sound deve considerar navegação por teclado, estrutura semântica, textos alternativos, foco visível, feedback compreensível e compatibilidade com leitores de tela.

3 MATERIAIS E MÉTODOS

3.1 Natureza do projeto

O See2Sound é um projeto de engenharia de software de caráter aplicado. O desenvolvimento adotou uma abordagem incremental: os módulos foram inicialmente construídos e testados de forma isolada e, posteriormente, integrados em uma pipeline única. Essa estratégia foi escolhida porque divergências em um componente de percepção podem se propagar para os módulos seguintes; portanto, a separação facilita a identificação da origem dos erros.

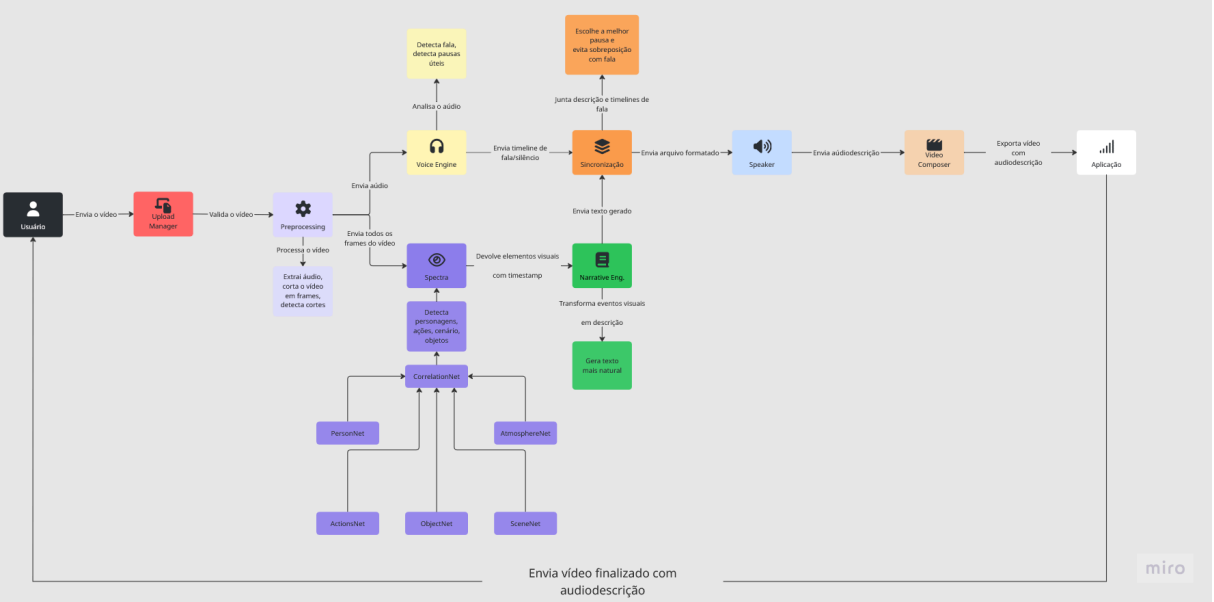
O backend foi desenvolvido principalmente em Python. Entre as dependências registradas no projeto estão OpenCV, MoviePy, NumPy, FFmpeg-Python, PyTorch, Torchvision, Transformers, Faster-Whisper, scikit-learn, llama-cpp-python e pyttsx3. Os testes automatizados são organizados com pytest e scripts específicos de demonstração e integração.

3.2 Arquitetura do sistema

A arquitetura geral foi dividida em módulos independentes, porém integrados. O fluxo previsto inicia com o envio de um arquivo de vídeo, passa pela validação e pré-processamento, segue para análise visual e sonora, geração narrativa, sincronização e síntese de voz, e termina com a composição de uma mídia audiodescrita.

No backend atual, a função de orquestração process_video centraliza grande parte desse fluxo. Ela valida o arquivo de entrada, cria diretórios de saída, coleta metadados, extrai áudio e frames, detecta mudanças de cena, executa o reconhecimento visual, constrói intervalos temporais, aciona o gerador narrativo e, quando habilitado, aciona o módulo de síntese de voz. Essa implementação permite habilitar ou desabilitar etapas individualmente, o que facilita experimentos e depuração.

Figura 1 - Pipeline geral do sistema See2Sound.



Fonte: elaboração própria (2026).

3.3 Pré-processamento audiovisual

O pré-processamento prepara a mídia para os modelos seguintes. São coletados metadados como duração e características do arquivo; o áudio é extraído separadamente; frames são amostrados em intervalos configuráveis; e mudanças de cena são detectadas para dividir o vídeo em segmentos temporais mais coerentes.

A análise de áudio utiliza Faster-Whisper por meio de um componente denominado WhisperPauseDetector. O sistema identifica trechos de fala e intervalos de silêncio, normaliza timestamps e procura a melhor pausa associada a cada cena. Essa etapa é necessária porque uma descrição semanticamente correta ainda pode ser inadequada se for inserida sobre diálogos ou sons essenciais.

3.4 Spectra: reconhecimento visual

A Spectra é a camada de percepção visual do sistema. Em vez de depender de um único classificador, o projeto organiza modelos especializados em subcategorias. O repositório atual contém estruturas separadas para reconhecimento de cenas, pessoas, ações, objetos e correlações, além de componentes de recorte de pessoas para permitir análises localizadas.

Os classificadores são implementados com PyTorch e utilizam arquiteturas de redes neurais convolucionais com backbones da família ResNet em diferentes pontos do projeto. Para tarefas multilabel, a saída é convertida em probabilidades

por função sigmoide e filtrada por limiares configuráveis. O projeto também aplica pós-processamento para reduzir duplicações e tornar as etiquetas mais adequadas à geração narrativa.

Ao longo do desenvolvimento, foram adicionados e refinados componentes específicos para reconhecimento de ações e objetos. O processo incluiu revisão dos conjuntos de dados, treinamento e ajuste fino do modelo de ações, além da evolução da rede responsável pelo reconhecimento de objetos. Também foi incorporado o MIT Indoor67 ao builder de cenas para ampliar a capacidade de reconhecer ambientes internos como escritórios, restaurantes e outros tipos de salas.

3.5 Narrative Engine

O Narrative Engine transforma a saída estruturada da Spectra em frases naturais. A versão atual utiliza um modelo Llama 3.2 1B Instruct quantizado, executado localmente por llama-cpp-python. O módulo foi dividido em componentes para construção de contexto, criação de prompt, filtragem de redundância, geração e verificação de fidelidade.

O filtro de fidelidade foi introduzido porque modelos de linguagem podem acrescentar detalhes plausíveis, porém não sustentados pelas detecções. O objetivo desse componente é sinalizar ou remover informações de risco, como gênero, idade, emoção ou características visuais não confirmadas, além de impedir que a descrição se afaste das etiquetas que deram origem ao texto.

Outro componente importante é o filtro de redundância. Cenas consecutivas podem produzir etiquetas semelhantes; narrá-las repetidamente comprometeria a experiência. Por isso, o módulo compara o contexto atual com descrições anteriores e busca evitar repetições que não acrescentem informação.

3.6 Voice Engine, sincronização e composição

A síntese de voz é realizada por um cliente TTS capaz de receber o texto final e gerar áudio narrado. O repositório também contém modelos de dados, construtor de timeline, mixer de áudio e um serviço de audiodescrição. Esses componentes têm a função de transformar descrições textuais em segmentos de áudio, alinhá-los à linha do tempo e preparar a composição com o conteúdo original.

A integração Spectra→Narrative constitui um dos principais fluxos avaliados no sistema. A etapa de TTS também pode ser habilitada pela função principal de processamento, permitindo avaliar aspectos como duração da narração, volume, continuidade do áudio e estabilidade da composição em diferentes tipos de vídeo.

3.7 Testes e critérios de avaliação

O repositório mantém testes para metadados, extração de áudio, extração de frames, detecção de cenas, análise por Whisper, execução da Spectra em um frame, processamento de vídeo e integração Spectra→Narrative. Também existem scripts de demonstração para Narrative e TTS. Essa estrutura permite verificar módulos isoladamente e depois testar o encadeamento de funções.

Para avaliação do sistema foram definidos os seguintes critérios:

- fidelidade visual: correspondência entre o texto gerado e as informações efetivamente detectadas;
- relevância narrativa: prioridade dada a acontecimentos importantes para a compreensão da cena;
- redundância: quantidade de descrições repetitivas;
- adequação temporal: compatibilidade entre duração da narração e pausa disponível;
- sobreposição com diálogos: ocorrência de audiodescrição sobre fala original relevante;
- tempo de processamento: relação entre duração da mídia e tempo necessário para processá-la;
- robustez: capacidade de concluir o fluxo sem falhas em diferentes arquivos;
- acessibilidade da interface: compatibilidade com princípios da WCAG 2.2.

A avaliação quantitativa dos submodelos considera métricas como acurácia, precisão, recall e F1, selecionadas de acordo com as características de cada tarefa de classificação. Essas métricas complementam a avaliação qualitativa do pipeline e permitem comparar versões dos modelos de maneira padronizada e reproduzível.

4 DESENVOLVIMENTO DO PROJETO

4.1 Organização em etapas

O desenvolvimento foi planejado em sprints. A primeira etapa concentrou-se na pesquisa sobre audiodescrição, visão computacional, reconhecimento de fala e síntese de voz, além da definição da arquitetura. Na sequência foram implementados leitura de vídeo, extração de áudio e frames, detecção de cenas e análise de pausas. Depois, o foco passou para os modelos da Spectra e para a transformação das etiquetas em narrativa.

A estrutura modular permitiu que diferentes partes avançassem em paralelo. Enquanto os componentes de percepção visual eram treinados e refinados, o Narrative Engine foi reorganizado para trabalhar com entradas estruturadas e o pipeline foi ampliado para executar os módulos de forma encadeada.

4.2 Evolução técnica do sistema

O desenvolvimento do See2Sound envolveu sucessivas melhorias na organização dos modelos, nos conjuntos de dados, no treinamento dos classificadores e na integração entre os módulos. A Tabela 1 apresenta alguns dos principais avanços técnicos incorporados ao sistema.

Tabela 1 - Marcos recentes de desenvolvimento registrados no GitHub.

Commit/marco	**Evolução técnica**	**Impacto no projeto**
Separação dos submodelos da Spectra em pastas	Organização de modelos especializados	Melhor modularidade e manutenção
Actions datasets v2	Revisão dos dados usados no módulo de ações	Preparação para novo treinamento
Spectra Actions v2 training	Treinamento da segunda versão do modelo de ações	Melhoria da percepção de atividades humanas
Kaggle Compatibility and Builder	Inclusão do MIT Indoor67 e exportação de dataset	Ampliação da classificação de ambientes e treinamento em Kaggle
Narrative process video test / Narrative new version	Integração do vídeo processado com o gerador narrativo	Fluxo integrado Spectra→Narrative
Actions v3 finetuned	Ajuste fino do modelo de ações	Refinamento das previsões de ações
Spectra object net	Evolução do modelo de objetos e limpeza de previsões	Ampliação de objetos reconhecíveis e redução de redundância

Fonte: repositório See2Sound_Backend (2026).

5 RESULTADOS E ANÁLISE DOS DADOS

5.1 Estado atual dos módulos

Um dos principais resultados do projeto é a consolidação de um backend modular capaz de executar uma sequência integrada de processamento audiovisual. Scripts de teste para metadados, áudio, frames, cenas, Whisper, Spectra e Narrative permitem verificar individualmente e de forma integrada as principais etapas da arquitetura.

Tabela 2 - Estado atual dos principais componentes.

Componente	Evidência atual	Situação
Pré-processamento	Metadados, extração de áudio, frames e detecção de cenas integrados ao process_video	Implementado e testável
Voice Engine - análise	WhisperPauseDetector identifica fala e pausas	Implementado e integrado à análise temporal
Spectra - cenas	Modelo e pipeline de treino; builder atualizado com MIT Indoor67	Implementado com processo contínuo de otimização
Spectra - pessoas	Modelo e recorte de pessoas disponíveis	Integrado ao pipeline
Spectra - ações	Versões v2 e v3 fine-tuned registradas em commits	Implementado com processo contínuo de otimização
Spectra - objetos	Rede de objetos ampliada e pós-processamento atualizado em 27/08	Implementado e integrado ao processo de reconhecimento visual
Narrative Engine	Llama local, prompt builder, filtros de redundância e fidelidade	Integrado e testado com saída textual
TTS e timeline	Cliente TTS, timeline builder e mixer presentes	Implementado no fluxo de síntese e composição
Composição final	Estruturas de audiodescrição e mixagem presentes	Estrutura de integração e composição implementada
Plataforma acessível	Arquitetura prevista e repositórios relacionados existentes	Componente complementar à arquitetura do backend

Fonte: elaboração própria a partir do código e histórico do projeto (2026).

5.2 Teste integrado Spectra → Narrative

Um dos testes de integração mais relevantes executou o processamento de um vídeo de teste com os módulos Spectra e Narrative habilitados. O script test_process_video_narrative.py carrega modelos para cena, pessoa e ação, utiliza o Llama local para gerar o texto e imprime, para cada cena, as etiquetas detectadas, seus níveis de confiança e a descrição final.

Em uma execução registrada durante o desenvolvimento, a Spectra retornou para uma cena de aproximadamente 19,93 segundos as etiquetas person, black_clothes, running, glasses, short_hair, fast_motion, field, moving, outdoor e

man. Entre as maiores confianças estavam outdoor (0,9733), fast_motion (0,9531), black_clothes (0,9085), man (0,8922) e field (0,8353). A partir dessas etiquetas, o Narrative Engine produziu a frase: “Ela está caminhando pela uma paisagem verde, com o sol brilhando no céu.”

O resultado demonstra duas características importantes. Primeiramente, a pipeline conseguiu converter uma coleção de etiquetas em uma frase sintaticamente compreensível e contextualizada, comprovando a viabilidade da integração entre percepção visual e geração textual. Em segundo lugar, a frase revelou problemas de fidelidade: a etiqueta man foi convertida para o pronome feminino “Ela”; running foi suavizada para “caminhando”; e “sol brilhando no céu” não estava explicitamente presente entre as etiquetas fornecidas. Essas divergências mostram que naturalidade linguística, isoladamente, não é suficiente para uma audiodescrição confiável.

A observação desse erro motivou o fortalecimento do filtro de fidelidade e a criação de regras voltadas a informações de risco, incluindo gênero, idade, emoções e detalhes visuais não confirmados. Assim, o próprio teste funcionou como instrumento de engenharia: a divergência observada não foi apenas registrada, mas utilizada para orientar a arquitetura da versão seguinte.

Tabela 3 - Análise qualitativa do teste Spectra→Narrative.

Elemento	**Saída observada**	**Análise**
Reconhecimento visual	Etiquetas coerentes com pessoa, movimento, ambiente externo e vestimenta	Indica que a Spectra consegue fornecer contexto útil para o gerador
Naturalidade textual	Frase curta e fluida	Resultado positivo para legibilidade
Gênero	man → “Ela”	Erro de fidelidade semântica
Ação	running → “caminhando”	Perda de intensidade e alteração do evento
Detalhe adicional	“sol brilhando no céu”	Inferência não sustentada pelas etiquetas apresentadas
Consequência técnica	Criação/reforço de filtro de fidelidade	A falha direcionou melhorias na arquitetura

Fonte: dados de teste do projeto See2Sound (2026).

5.3 Desafios técnicos identificados

Os testes realizados permitiram identificar desafios técnicos relevantes para o aprimoramento da arquitetura e da qualidade das audiodescrições geradas. A primeira é a propagação de erro: uma classificação visual incorreta pode resultar em

uma descrição incorreta mesmo que o modelo de linguagem funcione perfeitamente. A segunda é a alucinação do modelo narrativo, que pode acrescentar detalhes plausíveis para tornar a frase natural. A terceira é a limitação temporal, pois uma descrição correta pode ser longa demais para a pausa disponível.

Também foram observados desafios relacionados à generalização dos modelos. Vídeos apresentam variações de iluminação, enquadramento, movimento, número de pessoas, estilos de edição e ambientes. Por esse motivo, a inclusão de novos conjuntos de dados e o refinamento de submodelos têm sido parte recorrente do desenvolvimento.

A avaliação com pessoas cegas ou com baixa visão constitui uma etapa relevante para mensurar a experiência de uso e a utilidade prática das audiodescrições produzidas. A análise apresentada neste trabalho concentra-se na validação técnica da arquitetura, da integração entre os módulos e da fidelidade das descrições geradas.

6 DISCUSSÃO

Os resultados obtidos sustentam a viabilidade da arquitetura modular proposta. O backend já executa etapas que, no plano de pesquisa, apareciam como componentes futuros: pré-processamento, análise de pausas, reconhecimento visual e geração narrativa possuem implementações concretas e testes associados. O histórico de desenvolvimento também evidencia a evolução contínua dos modelos e da integração entre os componentes.

Ao mesmo tempo, o teste integrado evidencia que a principal dificuldade do problema não é simplesmente produzir uma frase a partir de uma imagem. Uma audiodescrição útil exige fidelidade, seleção e contexto. O erro em que “man” foi convertido para “Ela” é especialmente significativo porque demonstra como um modelo generativo pode contrariar diretamente uma informação fornecida pela camada de percepção. Esse tipo de erro seria inadequado em um sistema de acessibilidade, pois o usuário depende justamente da descrição para acessar uma informação que não consegue verificar visualmente.

Nesse sentido, a decisão de dividir o Narrative Engine em geração, contexto, redundância e fidelidade é coerente com a literatura sobre audiodescrição. David, Hautequestt e Kastrup (2012) argumentam que a audiodescrição envolve escolhas e experiência, não apenas objetividade mecânica. Para uma solução automática, isso significa equilibrar dois extremos: frases rígidas e pouco naturais, que apenas listam rótulos, e frases excessivamente livres, que acrescentam informações não verificadas.

A análise de pausas por Whisper também representa uma diferença importante em relação a sistemas que apenas descrevem frames. A audiodescrição é um fenômeno temporal; portanto, o momento de inserção pode ser tão relevante quanto o texto. A abordagem adotada de relacionar cenas e intervalos de fala cria condições para que, futuramente, o sistema escolha descrições compatíveis com o espaço disponível.

A avaliação quantitativa constitui um importante complemento à análise técnica do sistema. Um protocolo padronizado permite comparar versões dos modelos por meio da precisão das etiquetas, taxa de descrições fiéis, incidência de inferências não sustentadas, duração das narrações e sobreposição com falas.

Por fim, deve-se destacar que o See2Sound não pretende substituir o trabalho profissional de audiodescritores em produções que exigem alta qualidade artística e editorial. Seu potencial está principalmente em ampliar a disponibilidade de um recurso de acessibilidade para a grande quantidade de conteúdo digital que atualmente não recebe qualquer audiodescrição.

7 CONCLUSÕES

O desenvolvimento do See2Sound demonstrou que é tecnicamente possível integrar processamento de vídeo, reconhecimento de fala, visão computacional e modelos de linguagem em uma pipeline destinada à geração automática de audiodescrição. O projeto avançou de uma arquitetura conceitual para um backend modular com componentes implementados, modelos especializados e testes de integração.

Os resultados obtidos confirmam que a Spectra é capaz de produzir informações visuais utilizáveis pelo Narrative Engine e que o modelo de linguagem consegue transformar essas informações em frases naturais. Entretanto, também demonstram que a naturalidade textual pode introduzir erros de fidelidade, evidenciando a necessidade de mecanismos específicos de validação e filtragem. Dessa forma, um dos principais aprendizados do projeto foi que a qualidade da audiodescrição automática depende tanto da percepção visual quanto do controle sobre o comportamento generativo.

A hipótese de engenharia subjacente ao projeto – de que diferentes módulos de inteligência artificial podem ser combinados para automatizar etapas da audiodescrição – foi validada pela implementação e integração dos componentes desenvolvidos. A arquitetura construída também estabelece uma base extensível para avaliações quantitativas, otimizações de desempenho, refinamento dos modelos e estudos de usabilidade e acessibilidade.

Conclui-se, portanto, que o See2Sound apresenta uma base funcional e tecnicamente promissora para geração automática de audiodescrição contextualizada, com potencial para ampliar o acesso a conteúdos audiovisuais digitais. Os resultados também apontam oportunidades de evolução relacionadas à fidelidade narrativa, à redução de inferências não sustentadas, à sincronização temporal e à avaliação da experiência do público-alvo.

8 PERSPECTIVAS DE APRIMORAMENTO

A arquitetura modular do See2Sound permite diferentes possibilidades de expansão e aprimoramento. Entre as perspectivas identificadas estão:

- ampliar a avaliação dos submodelos de cenas, pessoas, ações e objetos utilizando conjuntos de teste independentes;
- aprofundar a análise quantitativa por meio de métricas de precisão, recall, F1 e acurácia;
- estruturar conjuntos de avaliação específicos para audiodescrição, com cenas anotadas e descrições de referência;
- aperfeiçoar mecanismos automáticos de comparação entre etiquetas visuais e textos gerados;
- otimizar a seleção das descrições de acordo com a duração das pausas disponíveis;
- expandir os testes de síntese de voz, mixagem e composição audiovisual;
- avaliar o desempenho do processamento em diferentes durações e resoluções de vídeo;
- aprofundar a avaliação da interface segundo as recomendações WCAG 2.2;
- ampliar a avaliação da experiência de uso junto ao público-alvo, observadas as exigências éticas aplicáveis;
- aperfeiçoar a documentação de datasets, modelos, hiperparâmetros e resultados experimentais.

REFERÊNCIAS

DAVID, Jéssica; HAUTEQUESTT, Felipe; KASTRUP, Virginia. Audiodescrição de filmes: experiência, objetividade e acessibilidade cultural. Fractal: Revista de Psicologia, Niterói, v. 24, n. 1, p. 125-142, 2012. DOI: 10.1590/S1984-02922012000100009.

ORGANIZAÇÃO MUNDIAL DA SAÚDE. Blindness and vision impairment. Geneva: WHO, 10 fev. 2026. Disponível em: https://www.who.int/news-room/fact-sheets/detail/blindness-and-visual-impairment. Acesso em: 27 ago. 2026.

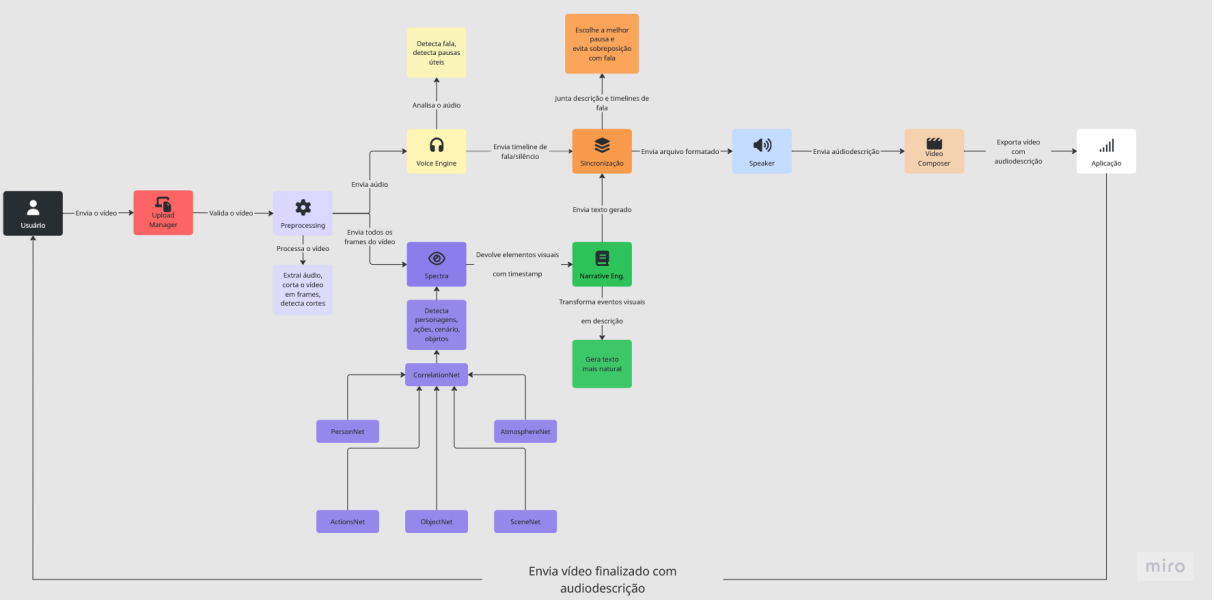
SEE2SOUND. See2Sound_Backend: backend service for See2Sound. GitHub, 2026. Disponível em: https://github.com/ClarAlvez/See2Sound_Backend. Acesso em: 27 ago. 2026.

WORLD WIDE WEB CONSORTIUM. Web Content Accessibility Guidelines (WCAG) 2.2. W3C Recommendation, 12 dez. 2024. Disponível em: https://www.w3.org/TR/WCAG22/. Acesso em: 27 ago. 2026.

APÊNDICE A - PIPELINE DO SEE2SOUND

O diagrama a seguir representa a arquitetura planejada do projeto e a relação entre os módulos principais. O usuário envia um vídeo; o sistema realiza upload e pré-processamento; o áudio segue para o Voice Engine, enquanto frames são encaminhados à Spectra; as informações visuais são transformadas em texto pelo Narrative Engine; a sincronização combina descrições e intervalos de fala; o Speaker produz a narração; e o Video Composer prepara o conteúdo final para retorno à aplicação web.

Figura A.1 - Arquitetura e fluxo atuais do See2Sound.



Fonte: elaboração própria (2026).